

NOTE MÉTHODOLOGIQUE

ANALYSE EXPLORATOIRE

Projet : Analyse des villes les plus attractives pour un investissement immobilier en France

Etudiant

Karim CHAMI

Formation

Mastère 2 AI & Data Science

Date

09 Juin 2026

1. PROBLÈME CHOISI

Présentation du client

Le client est un investisseur immobilier, une agence spécialisée ou tout acteur souhaitant identifier les villes françaises offrant les meilleures opportunités d'investissement locatif.

Dans un contexte où les prix immobiliers varient fortement selon les territoires, il devient difficile de déterminer quelles villes permettent d'obtenir le meilleur rendement tout en limitant les risques liés à l'investissement.

Problématique métier

L'objectif du projet est de répondre à la question suivante :

Quelles villes françaises offrent le meilleur potentiel pour un investissement immobilier locatif rentable et durable ?

Cette problématique est particulièrement importante pour les investisseurs qui cherchent à optimiser leur rentabilité sans se limiter aux grandes métropoles traditionnellement attractives.

Problème identifié

De nombreux investisseurs privilégient les villes les plus connues ou les marchés immobiliers les plus dynamiques sans nécessairement analyser leur rentabilité réelle.

Or :

- Les villes les plus chères ne sont pas toujours les plus rentables ;
- Les loyers élevés ne compensent pas toujours les prix d'achat ;
- Certaines villes moyennes offrent parfois de meilleures opportunités d'investissement.

L'enjeu est donc d'identifier les facteurs qui influencent réellement le rendement locatif afin d'aider les investisseurs à prendre des décisions fondées sur les données.

2. DATASET RETENU

Objectif du choix des données

Pour calculer la rentabilité d'un investissement immobilier, deux informations sont indispensables :

- Le prix d'acquisition du bien ;
- Le revenu locatif potentiel.

Deux jeux de données publics ont donc été sélectionnés puis fusionnés afin d'obtenir une vision complète du marché immobilier français.

Dataset 1 : Demandes de Valeurs Foncières (DVF)

Source officielle

<https://www.data.gouv.fr/datasets/demandes-de-valeurs-foncieres>

Producteur

Direction Générale des Finances Publiques (DGFIP)

Description

Le fichier DVF recense l'ensemble des transactions immobilières réalisées en France à partir des actes notariés et des données cadastrales.

Il constitue aujourd'hui la référence publique pour l'analyse des prix immobiliers.

Variables retenues

Variable	Description
ville	Commune
departement	Département
prix_m2	Prix moyen au m ²
nb_transactions	Nombre de transactions

Pertinence métier

Ce dataset permet d'estimer le coût d'acquisition moyen d'un bien immobilier dans chaque ville française.

Dataset 2 : Carte des Loyers 2025

Source officielle

<https://www.data.gouv.fr/datasets/carte-des-loyers-indicateurs-de-loyers-dannonce-par-commune-en-2025>

Producteurs

- Agence Nationale pour l'Information sur le Logement (ANIL)
- SeLoger
- Leboncoin

Description

Ce jeu de données fournit des estimations des loyers d'annonces observés dans les communes françaises.

Les indicateurs sont construits à partir de plusieurs millions d'annonces immobilières publiées sur les principales plateformes françaises.

Variables retenues

Variable	Description
ville	Commune
departement	Département
REG	Région
loypredm2	Loyer estimé au m ²

Pertinence métier

Ce dataset permet d'estimer le revenu locatif potentiel associé à un investissement immobilier.

Préparation des données

Les opérations suivantes ont été réalisées :

Nettoyage

- Suppression des valeurs aberrantes ;
- Suppression des valeurs manquantes ;
- Harmonisation des formats.

Filtrage

Afin de garantir la robustesse statistique :

- Seules les villes possédant plus de 30 transactions ont été conservées.

Fusion

Les deux jeux de données ont été fusionnés sur :

- La commune ;
- Le département.

Construction des indicateurs

Loyer annuel estimé

Pour standardiser l'analyse, un logement type de 50 m² a été considéré :

$\text{Loyer annuel} = \text{loypredm2} \times 50 \times 12$

Prix d'acquisition estimé

$\text{Prix estimé} = \text{prix_m2} \times 50$

Rendement locatif brut

$\text{Rendement (\%)} = (\text{Loyer annuel} / \text{Prix estimé}) \times 100$

Jeu de données final

Le dataset final comprend :

- Plus de 531 000 transactions immobilières ;
- Une couverture nationale ;
- Des données immobilières réelles ;
- Des données locatives actualisées.

Cette fusion permet d'obtenir une vision globale de l'attractivité immobilière des villes françaises.

3. TECHNOLOGIES UTILISÉES

Langage principal

Python

Python a été utilisé pour l'ensemble des traitements et analyses.

Librairies utilisées

Pandas

Utilisé pour :

- le nettoyage des données ;
- les jointures ;
- les transformations ;
- les calculs d'indicateurs.

NumPy

Utilisé pour :

- les calculs numériques ;
- les transformations mathématiques.

SciPy

Utilisé pour :

- les tests statistiques ;
- l'ANOVA ;
- le test du χ^2 ;
- la régression linéaire.

Matplotlib

Utilisé pour :

- les visualisations statistiques ;
- les graphiques exploratoires.

Seaborn

Utilisé pour :

- les heatmaps ;
- les matrices de corrélation ;
- les visualisations avancées.

Tableau Public

Utilisé pour :

- la création du dashboard interactif ;
- la restitution des résultats métiers.

Architecture analytique

Collecte des données



Nettoyage



Fusion des datasets



Analyse exploratoire (EDA)



Tests statistiques



Visualisations



Dashboard interactif



Recommandations métier

Cette architecture facilite le transfert du projet vers une autre équipe Data.

4. HYPOTHÈSES ET TESTS

L'objectif est d'identifier les facteurs influençant la rentabilité immobilière.

Hypothèse 1 : Le rendement locatif varie selon les régions françaises

Intuition métier

Les régions françaises possèdent des caractéristiques économiques et immobilières différentes.

Il est donc pertinent de vérifier si les rendements moyens observés diffèrent selon les régions.

Test utilisé

ANOVA à un facteur.

Hypothèses

H_0 : Les rendements locatifs moyens sont identiques entre les régions.

H_1 : Au moins une région présente un rendement moyen différent.

Résultats

- Statistique F = 22,25
- p-value = $8,47 \times 10^{-63}$

Décision

La p-value est largement inférieure à 0,05.

-- Rejet de H_0 .

Interprétation métier

Les rendements locatifs diffèrent significativement selon les régions françaises.

Cela signifie que :

- certaines régions offrent des rendements plus élevés ;
- la localisation constitue un facteur déterminant ;
- la région doit être intégrée dans toute stratégie d'investissement.

Hypothèse 2 : La région influence la catégorie de rendement

Intuition métier

Certaines régions pourraient concentrer davantage de villes à rendement élevé.

Test utilisé

Test du χ^2 d'indépendance.

Variables

- Région
- Catégorie de rendement (Faible, Moyen, Bon)

Hypothèses

H_0 : Région et catégorie de rendement sont indépendantes.

H_1 : Région et catégorie de rendement sont dépendantes.

Résultats

- $\chi^2 = 432,19$
- Degrés de liberté = 48
- p-value = $3,04 \times 10^{-63}$

Décision

La p-value est inférieure à 0,05.

-- Rejet de H_0 .

Interprétation métier

La région influence significativement la catégorie de rendement observée.

Certaines régions regroupent davantage de villes :

- à fort rendement ;
- à rendement moyen ;
- à faible rendement.

Le choix de la région constitue donc un critère stratégique pour l'investisseur.

Hypothèse 3 : Le prix au m² influence le rendement locatif

Intuition métier

Le rendement dépend directement du rapport entre les loyers et le coût d'acquisition du bien.

Test utilisé

Régression linéaire simple.

Hypothèses

H_0 : Il n'existe pas de relation linéaire entre le prix au m² et le rendement.

H_1 : Le rendement dépend du prix au m².

Résultats

- Pente = -0,000603
- $R^2 = 0,488$
- p-value < 0,001

Décision

La p-value est significative.

-- Rejet de H_0 .

Interprétation métier

Lorsque le prix au m² augmente :

- le rendement tend à diminuer ;
- les villes les plus chères deviennent moins rentables.

Le prix au m² explique près de 49 % de la variation du rendement locatif.

5. SYNTHÈSE DES RÉSULTATS

Résultats techniques

Corrélations observées

Variables	Corrélation
Prix au m ² / Loyers	+0,69
Prix au m ² / Rendement	-0,70
Loyers / Rendement	-0,11

Principaux enseignements

Les analyses montrent que :

- le rendement locatif varie selon les régions ;
- la région influence la catégorie de rendement ;
- les villes les plus chères offrent généralement des rendements plus faibles ;
- le prix au m² explique près de 49 % de la variation du rendement.

Villes les plus rentables identifiées

Parmi les villes analysées :

- Grigny
- Lapalisse
- Saint-Claude
- Grand-Charmont

présentent des rendements supérieurs à la moyenne nationale.

Visualisations produites

Les résultats sont illustrés à travers :

- matrice de corrélation ;
- nuage de points prix/rendement ;
- boxplots régionaux ;
- carte de France des rendements ;
- dashboard Tableau interactif.

6. FORMULATION AUPRÈS DU CLIENT

Ce qu'il faut retenir

L'analyse démontre que la rentabilité immobilière dépend principalement de deux facteurs :

1. La région où se situe le bien.
2. Le prix d'acquisition au m².

Contrairement aux idées reçues, les villes les plus chères ne sont pas nécessairement les plus rentables.

Les meilleures opportunités se trouvent souvent dans des villes où :

- les prix restent modérés ;
- les loyers demeurent attractifs.

Recommandations

Pour maximiser le rendement

Privilégier :

- les villes avec un rendement supérieur à 6 % ;
- les villes présentant un bon équilibre prix/loyer ;
- les régions historiquement performantes.

Pour limiter les risques

Compléter l'analyse avec :

- la vacance locative ;
- la dynamique démographique ;
- l'emploi local ;
- l'attractivité économique.

7. LIMITES ET AMÉLIORATIONS POSSIBLES

Limites

L'étude repose sur le rendement locatif brut.

Les éléments suivants n'ont pas été intégrés :

- fiscalité ;
- charges de copropriété ;
- frais de gestion ;
- travaux ;
- vacance locative ;
- coût du financement.

Par ailleurs, les loyers utilisés sont des loyers estimés et non des loyers observés pour chaque bien.

Améliorations possibles

Enrichissement des données

Ajouter :

- les revenus des ménages ;
- le taux de chômage ;
- la croissance démographique ;
- la vacance locative ;
- les indicateurs de tension locative.

Analyse avancée

Développer :

- un score global d'investissement ;
- un modèle prédictif de rendement ;
- une segmentation des villes ;
- des algorithmes de recommandation.

CONCLUSION GÉNÉRALE

Cette étude met en évidence que la rentabilité immobilière varie significativement selon les territoires français.

Les analyses statistiques démontrent que la région et le prix au m² constituent les principaux déterminants du rendement locatif.

Les investisseurs ont donc intérêt à privilégier les villes offrant le meilleur équilibre entre prix d'acquisition modéré et niveau de loyer attractif plutôt que de cibler uniquement les marchés immobiliers les plus valorisés.

L'approche proposée permet ainsi de transformer des données immobilières complexes en recommandations concrètes et actionnables pour la prise de décision.